Autojogo com Memória em Contexto para Simulação de Vendas B2B: Resultados Preliminares e Lições sobre o Desenho de Incentivos

[Autores]
[Afiliação]

Relatório técnico — setembro de 2026

Resumo

Apresentamos uma arena de simulação em que dois agentes baseados em um mesmo modelo de linguagem (MiniMax-M3) negociam vendas B2B em português: um *comprador*, que interpreta um gestor de uma empresa brasileira real ou sintética com informações privadas (orçamento, dores, papel na decisão), e um *vendedor* de um produto fictício com ficha técnica verificável. As jornadas percorrem cold call, reunião de diagnóstico (*discovery*), prova de conceito (PoC) simulada e negociação de fechamento, com placar objetivo de soma zero. Os agentes aprendem sem ajuste de pesos, por memória em contexto: um crítico extrai lições condicionais após cada conversa; um consolidador as funde em versões de um *playbook*; a recuperação usa similaridade por atributos com amostragem de Thompson. Comparamos duas ligas que diferem apenas no crítico: *realista* (não vê as informações ocultas do oponente) e *onisciente* (vê). Em 36 rodadas completas, 956 conversas e 10.749 turnos, apenas o vendedor com crítico realista melhorou de forma estatisticamente detectável contra um painel fixo de oponentes (8 melhores, 1 pior em avaliações pareadas; teste de sinais, $p \approx 0{,}04$). O achado mais consequente, porém, é sobre incentivos: uma regra de placar que tratava "encerrar a ligação" como vitória do comprador, independentemente do *fit*, foi explorada pelo autojogo e produziu compradores-porteiros irrealistas (reuniões com *fit* alto caíram a 0%). Discutimos a assimetria estrutural do fechamento sob informação privada, a necessidade de coerência entre *fit* e dor nos cenários e a calibração do comprador antes do autojogo. Os resultados são preliminares: a amostra é pequena e as regras foram corrigidas durante a execução.

1 Introdução

Simuladores de clientes baseados em LLMs são promissores para treinar vendedores humanos, mas só têm valor se o comportamento simulado for realista: um cliente fácil demais ensina hábitos errados, e um cliente impossível não ensina nada. Uma forma natural de produzir agentes exigentes é o *autojogo* (*self-play*), no qual comprador e vendedor se aprimoram um contra o outro. Em jogos de dois jogadores com soma zero, espera-se que o autojogo tenda a um equilíbrio; neste trabalho perseguimos, como meta operacional, uma taxa de vitória próxima de 50/50.

Este relatório descreve (i) um ambiente de simulação de vendas B2B com jornada encadeada, informação privada, verificação objetiva de promessas e placar objetivo; (ii) um mecanismo de aprendizado em contexto, sem ajuste de pesos, com memória em três camadas; e (iii) um experimento controlado que compara dois tipos de crítico. Nossas contribuições são:

1. Uma arquitetura aberta de arena de vendas com passos síncronos (ligação) e assíncronos (propostas por e-mail), placar objetivo derivado de ações estruturadas e verificação de afirmações contra ficha técnica.

2. Evidência preliminar de que um crítico *realista* gera memória útil ao vendedor, enquanto um crítico *onisciente* não gera, e ainda aumenta afirmações falsas.
3. Um estudo de caso de *exploração de incentivo*: como uma regra de placar aparentemente razoável levou o autojogo a produzir compradores irrealistas, e como corrigi-la.
4. Um diagnóstico dos obstáculos ao equilíbrio 50/50 (assimetria do fechamento, incoerência entre *fit* e dor, ausência de calibração) e recomendações concretas.

2 Trabalhos relacionados

Negociação entre LLMs. Conjuntos de dados clássicos de negociação humana incluem *Deal or No Deal* [7] e CraigslistBargain [6]. Com LLMs, Fu et al. [4] mostram que dois modelos em papéis de comprador e vendedor melhoram por autojogo com feedback de um terceiro modelo crítico, mecanismo que adaptamos. NegotiationArena [1] avalia LLMs em jogos de ultimato, troca e compra e venda, e mostra que táticas comportamentais alteram substancialmente os ganhos. Magentic Marketplace [8] estuda mercados de agentes e sua vulnerabilidade à manipulação.

Simulação social e de clientes. SOTOPIA [14] avalia inteligência social com objetivos privados e juiz LLM. Zhou et al. [15] alertam que simulações em que os agentes conhecem os objetivos um do outro parecem bem-sucedidas demais, o que motiva nossa assimetria de informação. SalesLLM [10] avalia vendedores LLM contra simuladores de clientes com níveis de dificuldade e mostra que a escolha do simulador altera fortemente os rankings. Nosso foco é B2B, com jornada de múltiplas reuniões.

Aprendizado por memória. Reflexion [11] e ExpeL [13] extraem lições de episódios passados e as reinjetam no contexto. Estendemos essa ideia com condições por atributos, estatística Beta de utilidade por lição e amostragem de Thompson [12] para equilibrar exploração e aproveitamento, além de consolidação versionada.

Técnicas de venda. Os estilos e técnicas dos agentes derivam de SPIN Selling [9], The Challenger Sale [2], MEDDIC e da literatura de negociação baseada em princípios [3]. As âncoras de realismo vêm de estatísticas públicas de conversas reais, como a proporção de fala do vendedor [5].

3 Ambiente

3.1 Cenários

Cada jornada é gerada por código a partir de: uma empresa (cinco empresas reais listadas na B3, com dossiês de dados públicos, ou uma empresa sintética derivada delas com nome fictício); um cargo (CTO, CFO, COO, Compras ou Comercial) e um papel (decisor ou influenciador); um de oito produtos fictícios (cibersegurança, atendimento com IA, telemetria de frota, agricultura de precisão, MES, contas a pagar, FinOps e treinamento), cada um com ficha técnica que separa funcionalidades *existentes*, *roadmap* e *limitações*. O código sorteia as **verdades ocultas**:

- *fit* real $\in [0{,}05; 0{,}95]$, a partir de uma matriz produto×empresa com ruído;
- orçamento do comprador = preço de tabela $\times\, U(0{,}85; 1{,}15)$;
- piso do vendedor (desconto máximo autorizado, de 10% a 25%);
- fatos privados do comprador com nível de revelação (FÁCIL/MÉDIO/DIFÍCIL) e regra oculta do chefe (para influenciadores).

Seguimos o princípio de que números e verdades ocultas vêm do código; o LLM apenas redige a narrativa.

3.2 Jornada e protocolo de turno

A jornada encadeia cold call ($\leq$8 min), *discovery* ($\leq$25 min), PoC simulada e fechamento ($\leq$25 min). Para cobrir todos os estágios, 50% das jornadas começam na cold call e 25% em cada

um dos outros estágios, com um histórico anterior sintético. Em cada turno, o agente emite uma saída estruturada: `<pensamento>` (privado), `<estado>` (quadro de crenças reescrito a cada turno), `<tecnica>`, `<fala>` (única parte vista pelo oponente) e `<acoes>` (propostas e decisões formais). O relógio é derivado das palavras faladas (150 palavras/min). Um árbitro verifica estagnação a cada 10 turnos. Guardas de código rejeitam alfabetos não latinos, vazamento de estratégia na fala e falas longas demais. Após a reunião, há passos assíncronos: proposta escrita de PoC ou proposta comercial, contraproposta do comprador, palavra final do vendedor e decisão.

3.3 Placar

O placar é de soma zero (+1 vendedor, 0 empate, −1 comprador), calculado por código a partir das ações:

- **Cold call:** reunião marcada com *fit* $\geq 0{,}5 \Rightarrow +1$; reunião sem *fit* $\Rightarrow -1$.
- **Discovery:** PoC aceita com critério de sucesso $\Rightarrow +1$.
- **PoC:** sucesso sorteado com probabilidade $p = \mathit{fit} \cdot \prod 0{,}5^{\#\text{falsas}}\, 0{,}75^{\#\text{exageros}}$, sobre as afirmações materiais do vendedor.
- **Fechamento** (regra do proponente do estudo): preço > orçamento $\Rightarrow +1$; preço $\approx$ orçamento $\Rightarrow 0$; preço < orçamento $\Rightarrow -1$; sem acordo $\Rightarrow 0$. Há penalidade adicional de pós-venda quando o contrato foi fechado sobre afirmações falsas.
- **Regra do chefe:** para influenciadores, um extrator LLM lê o relatório ao chefe e uma regra de código aprova apenas com recomendação explícita, retorno quantificado e sem riscos críticos em aberto.

Um verificador LLM classifica cada afirmação do vendedor em *verdadeira*, *exagero*, *roadmap vendido como pronto*, *falsa* ou *não verificável*, contra a ficha técnica.

4 Aprendizado em contexto

Memória em três camadas. (M1) *trabalho*: janela de 10 turnos literais, resumo rolante *append-only* (preserva prefixos para cache) e estado de crenças. (M2) *jornada*: ficha de CRM do vendedor e notas internas do comprador, incluindo o registro de promessas ouvidas. (M3) *estratégica*, por estilo (4 vendedores: consultivo, challenger, técnico, fechador; 4 compradores: analítico, político, negociador, ocupado): um *playbook* sempre ativo ($\leq$600 tokens) e lições condicionais recuperadas por semelhança.

Lições. Cada lição tem uma condição sobre atributos (setor, porte, maturidade digital, cargo, papel, estágio, estilo do oponente; `null` = curinga), uma ação, um mecanismo ("porque") e parâmetros (α, β) de uma distribuição Beta de utilidade. Na recuperação, cada lição recebe o escore $s = \text{match} \cdot u$, com $u \sim \text{Beta}(\alpha, \beta)$ (amostragem de Thompson), e há um limite por tema. A recuperação é puramente código.

Crítico e crédito. Após cada call, um crítico LLM recebe a transcrição, os pensamentos privados do mentorado, o resultado e as lições injetadas. Ele indica quais lições foram aplicadas e com qual efeito ($\alpha \mathrel{+}= 1$ se ajudou, $\beta \mathrel{+}= 1$ se atrapalhou) e propõe de 0 a 3 lições novas, que passam por validação (sem nomes do caso, sem valores absolutos, perspectiva correta).

Consolidação versionada. Dentro de uma rodada, todas as jornadas leem uma versão congelada da memória. Ao fim, um consolidador funde duplicatas, generaliza e reescreve o *playbook*, e o código aposenta lições com média Beta < 0,35 após pelo menos 5 usos. As rodadas alternam o lado aprendiz; o pareamento usa Elo, com 20% de oponentes de versões antigas (*hall of fame*).

Críticos comparados. No crítico *realista*, as informações ocultas do oponente não são reveladas ao crítico. No crítico *onisciente*, o crítico do vendedor recebe o orçamento real, o *fit* e o papel do comprador, e o crítico do comprador recebe o piso do vendedor.

5 Protocolo experimental

Ambas as ligas usam o mesmo modelo (MiniMax-M3, via gateway compatível com a API Anthropic) nos dois lados, no crítico e nos juízes, com temperaturas de 0,7 (vendedor), 0,8 (comprador) e ≈0 (juízes). Cada liga tinha teto de 330 mi de tokens contados (entrada + saída; leitura de cache não conta), com rodadas de 16 jornadas. A execução foi interrompida pela cota de uso do provedor após ∼9h40 de corrida.

Medida de aprendizado. O placar da liga não mede aprendizado, porque os dois lados mudam. Usamos *avaliação pareada*: os mesmos cenários e sementes, contra um painel fixo de oponentes na versão inicial (v0), com o lado avaliado na versão v0 e na versão treinada. Reportamos a contagem melhor/igual/pior e o teste de sinais bicaudal.

Mudanças durante a execução. Por transparência: (i) a partir da rodada 2, contraproposta por escrito no fechamento; (ii) a partir da rodada 6, proposta de PoC por escrito e placar 0 para "retorno condicionado" na *discovery*; (iii) a partir da rodada 8 (liga A) e 10 (liga B), placar de cold call e *discovery* condicionado ao *fit* (§7.1). Os dados antes e depois dessas mudanças não são plenamente comparáveis.

6 Resultados

6.1 Volume e realismo de forma

Tabela 1: Volume do experimento.

	Liga A (realista)	Liga B (onisciente)	Total
Rodadas completas	14	22	36
Jornadas de liga concluídas	273	423	696
Jornadas de avaliação pareada	93	129	222
Conversas (calls)	382	574	956
Turnos de fala	4.347	6.402	10.749
Palavras faladas	189 mil	278 mil	467 mil
Lições criadas / ativas ao final	407 / 204	652 / 259	–
Tokens contados (mi)	25,2	38,2	63,4

Nas 956 calls, o vendedor ocupou em média 56% das palavras (âncora de conversas reais bem-sucedidas: ∼43% [5]); a mediana de palavras por fala foi de 50 para o vendedor e 36 para o comprador. Houve 7 falhas de formato e nenhuma inversão de papel detectada pela heurística. O cache de prompt do provedor se mostrou pouco confiável (a leitura de cache foi de ∼19% dos tokens contados), o que elevou o custo médio para ∼90 mil tokens por jornada.

6.2 Avaliação pareada

Tabela 2: Avaliações pareadas agregadas: versão treinada vs. v0, nos mesmos cenários, contra oponentes v0 fixos. Inclui uma avaliação avulsa ($n = 8$) e as periódicas ($n = 12$ cada).

Lado avaliado	Liga	Melhor	Igual	Pior	p (sinais)
Vendedor	**A (realista)**	**8**	11	**1**	**0,04**
Vendedor	B (onisciente)	6	21	5	1,00
Comprador	A (realista)	5	12	3	0,73
Comprador	B (onisciente)	3	24	5	0,73

Apenas o vendedor da liga realista melhorou de forma detectável (Tab. 2; delta médio de +0,33 a +0,50 ponto por jornada nas avaliações individuais). O crítico onisciente não produziu ganho mensurável. Os compradores não melhoraram contra vendedores fixos: as jornadas avaliadas com compradores treinados terminaram majoritariamente em empate.

6.3 Dinâmica da liga

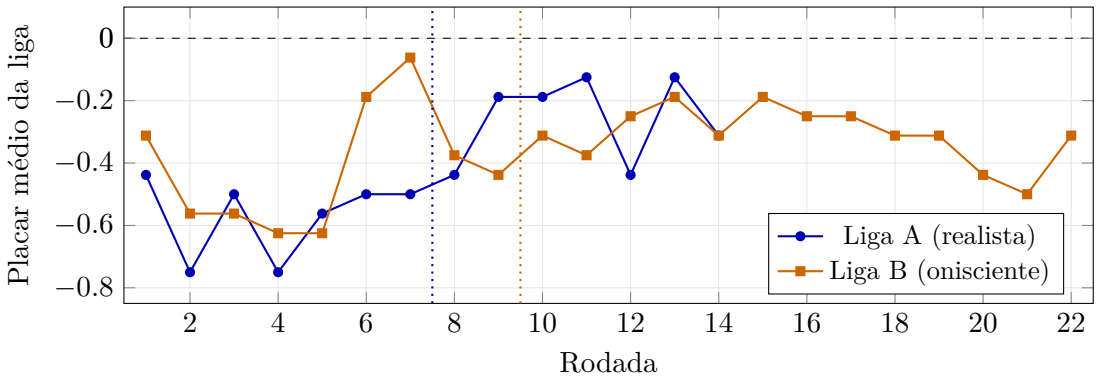


Figura 1: Placar médio por rodada (16 jornadas cada; negativo = vantagem do comprador). Rodadas ímpares: vendedores aprendem; pares: compradores. As linhas pontilhadas marcam a introdução do placar condicionado ao *fit* (A: rodada 8; B: rodada 10).

O placar da liga permaneceu negativo (vantagem do comprador) durante todo o experimento (Fig. 1). Na liga A, a média passou de −0,53 (143 jornadas antes da correção de incentivo) para −0,26 (130 depois); na liga B, de −0,41 para −0,31. Não houve convergência para o equilíbrio.

Tabela 3: Resultados por estágio antes e depois do placar condicionado ao *fit* (liga A). "Avançou" = objetivo do estágio atingido (reunião, PoC ou contrato).

Estágio	Período	n	Placar	Avançou	Turnos	Falsas/call
Cold call	antes	69	−0,26	3%	11,4	0,17
	depois	63	−0,10	0%	9,2	0,22
Discovery	antes	36	−0,81	3%	9,5	0,08
	depois	36	−0,22	0%	7,3	0,03
Fechamento	antes	40	−0,60	60%	12,3	0,47
	depois	31	−0,55	71%	8,0	0,19

Fechamento. Das 198 negociações de fechamento nas duas ligas, 130 terminaram em contrato, a um preço médio de 88% do orçamento do comprador e 87–88% do preço de tabela; apenas 8 fecharam acima do orçamento. As afirmações falsas por call no fechamento caíram na liga realista (0,47 → 0,19) e subiram na onisciente (0,28 → 0,48).

6.4 O que foi aprendido

As lições que sobreviveram à consolidação e à estatística de crédito incluem, para vendedores:

- "responder 100% do que o comprador perguntou antes de fazer qualquer pergunta minha";
- "no máximo uma pergunta por turno";
- "não revelo preço, referência nem proposta sem troca explícita";
- "declaro o *gap* em uma frase";
- "nunca verbalizo números que não constam na ficha";
- transformar "manda material" em compromissos verificáveis.

São práticas coerentes com a literatura de vendas consultivas e de negociação [2, 3, 9]. Para compradores, as lições convergiram para filtragem agressiva: "filtro de relevância em 30 segundos", "antes de revelar volume, orçamento ou sistemas, devolvo pergunta de competência". O crítico atribuiu às lições aplicadas 729 efeitos "ajudou" contra 209 "atrapalhou", mas essa autoavaliação é enviesada e não substitui a avaliação pareada.

7 Discussão

7.1 Exploração de incentivo: o comprador-porteiro

Na versão inicial do placar, encerrar a cold call ou a *discovery* sem próximo passo era vitória do comprador, *mesmo quando o produto resolvia uma dor real dele*. O autojogo explorou essa brecha:

- as lições dos compradores passaram a prescrever bloqueio universal ("em qualquer estágio e com qualquer vendedor, exijo prova antes de revelar qualquer coisa");
- as cold calls encurtaram de ∼14 para ∼9 turnos;
- a taxa de reunião com *fit* $\geq 0{,}5$ caiu de 3–6% para 0%.

Condicionamos o placar ao *fit*: parar sem *fit* continua sendo vitória do comprador (filtrou bem), mas parar com *fit* passa a ser empate (o vendedor não abriu a porta, e o comprador perdeu uma solução útil). A correção melhorou o placar médio, mas não restaurou a taxa de reuniões dentro da janela observada, porque a memória já acumulada continuou prescrevendo bloqueio. A lição metodológica é que, em autojogo, **o placar é o hiperparâmetro mais sensível**, e a deriva de realismo precisa ser monitorada como métrica de primeira classe.

7.2 Por que o crítico onisciente não ajuda

Nossa hipótese é que um crítico com acesso ao orçamento real e ao *fit* escreve lições cuja condição de aplicação depende de informação que o vendedor não observa durante a call. Elas parecem corretas *ex post*, mas não são acionáveis *ex ante*. O aumento de afirmações falsas na liga B sugere, adicionalmente, que conhecer o que "funcionou" sem conhecer o porquê observável incentiva atalhos retóricos.

7.3 Assimetria estrutural do fechamento

Sob a regra "o comprador vence se fechar abaixo do orçamento", um comprador racional, que conhece o próprio orçamento, nunca aceita preço acima dele: prefere recusar e empatar. O vendedor só vence se o comprador escolher estourar a verba pelo valor percebido, o que é raro. O dado de 122 contratos abaixo do orçamento em 130 confirma a assimetria. Uma regra simétrica, em que vence quem puxar o preço para o seu lado do ponto médio da zona de acordo entre piso e orçamento, torna o 50/50 alcançável por construção, porque ambos têm informação privada.

7.4 Coerência entre *fit* e dor

A inspeção de transcrições revelou cenários com *fit* alto em que a dor sorteada para o comprador não era resolvida pelo produto. Exemplo: *fit* 0,95 com a dor "vistoria de devolução por imagem" para um produto de telemetria. O comprador rejeitou corretamente. O *fit* (escalar) e a dor (texto) eram sorteados de forma independente dentro do mesmo tema. Isso contamina o sinal de aprendizado e parte da taxa de rejeição.

8 Limitações

- **Amostra pequena:** 20 a 32 pares por linha na Tab. 2. Apenas um resultado atinge $p < 0{,}05$, sem correção para comparações múltiplas.
- **Regras alteradas durante a execução** (§5): os dados antes e depois não são plenamente comparáveis.
- **Um único modelo** nos dois lados, no crítico e nos juízes, com possíveis vieses compartilhados.
- **Sem âncora humana:** não validamos se o comprador é realisticamente difícil, apenas difícil.
- **Juízes LLM:** o verificador de afirmações e o extrator do relatório ao chefe podem errar; não foram auditados manualmente em escala.
- **Métricas de realismo de forma**, e não de conteúdo, derivadas de estatísticas em inglês e de outro mercado.
- **Execução curta:** interrompida a ∼10% do orçamento planejado; a avaliação final com ablação (*playbook* vs. lições) não foi executada.

9 Trabalhos futuros

1. Gerar dores coerentes com o *fit* (resolvidas por funcionalidades *existentes* quando o *fit* é alto; adjacentes quando é baixo).
2. Adotar a regra de fechamento pelo ponto médio e comparar com a regra atual.
3. Calibrar o comprador em cenários de controle antes do autojogo (por exemplo, *fit* alto com vendedor competente deve gerar reunião numa fração substancial dos casos).
4. Regularizar o realismo das lições do comprador (rejeitar regras universais de bloqueio) e monitorar a deriva por faixa de *fit*.
5. Executar a ablação *playbook* vs. lições com $n \geq 24$ por lado.
6. Validar com vendedores humanos jogando contra os compradores treinados.

10 Conclusão

Uma arena de autojogo com memória em contexto pode produzir vendedores LLM mensuravelmente melhores e com práticas coerentes com a literatura de vendas, desde que o crítico aprenda apenas com o que o agente pode observar. O resultado mais importante, porém, é negativo e metodológico: em autojogo, os agentes encontram e exploram brechas do placar, e um placar mal especificado produz simuladores irrealistas, justamente o oposto do que se deseja para treinar pessoas. Coerência de cenário, simetria do jogo e calibração prévia do simulador são pré-requisitos, e não refinamentos, para buscar um equilíbrio 50/50 que seja também realista.

Referências

[1] F. Bianchi, P. J. Chia, M. Yuksekgonul, J. Tagliabue, D. Jurafsky, J. Zou. How well can LLMs negotiate? NegotiationArena platform and analysis. *ICML*, 2024.

[2] M. Dixon, B. Adamson. *The Challenger Sale*. Portfolio, 2011.

[3] R. Fisher, W. Ury. *Getting to Yes*. Houghton Mifflin, 1981.

[4] Y. Fu, H. Peng, T. Khot, M. Lapata. Improving language model negotiation with self-play and in-context learning from AI feedback. *arXiv:2305.10142*, 2023.

[5] Gong Labs. Mastering the talk-to-listen ratio in sales calls. https://www.gong.io/resources/labs/talk-to-listen-conversion-ratio/.

[6] H. He, D. Chen, A. Balakrishnan, P. Liang. Decoupling strategy and generation in negotiation dialogues. *EMNLP*, 2018.

[7] M. Lewis, D. Yarats, Y. Dauphin, D. Parikh, D. Batra. Deal or no deal? End-to-end learning for negotiation dialogues. *EMNLP*, 2017.

[8] Microsoft Research. Magentic Marketplace: an open-source environment for studying agentic markets. *arXiv:2510.25779*, 2025.

[9] N. Rackham. *SPIN Selling*. McGraw-Hill, 1988.

[10] Sell more, play less: benchmarking LLM realistic selling skill. *arXiv:2604.07054*, 2026.

[11] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, S. Yao. Reflexion: language agents with verbal reinforcement learning. *NeurIPS*, 2023.

[12] W. R. Thompson. On the likelihood that one unknown probability exceeds another in view of the evidence of two samples. *Biometrika*, 25(3/4):285–294, 1933.

[13] A. Zhao, D. Huang, Q. Xu, M. Lin, Y.-J. Liu, G. Huang. ExpeL: LLM agents are experiential learners. *AAAI*, 2024.

[14] X. Zhou et al. SOTOPIA: interactive evaluation for social intelligence in language agents. *ICLR*, 2024.

[15] X. Zhou, Z. Su, T. Eisape, H. Kim, M. Sap. Is this the real life? Is this just fantasy? The misleading success of simulating social interactions with LLMs. *arXiv:2403.05020*, 2024.

A Exemplo de diálogo (discovery, liga de teste)

V: Você comentou que a integração cai no pico. [...] A PoC não precisa rodar nos três sistemas ao mesmo tempo. O que eu preciso entender com você é: desses três, qual é o que mais dói hoje, em volume ou em reclamação?
C: Faz sentido. Mas esse fluxo vai conversar com o sistema legado de verdade, ou com um espelho? Porque, se for espelho, eu já sei que vai funcionar.
V: Boa pergunta. [...] A PoC tem que falar com o legado real, não com espelho. Caso contrário, não prova nada.

B Trecho de *playbook* consolidado (vendedor consultivo, liga A)

"Em cold call, abro confirmando UM contexto público conhecido e pergunto onde dói hoje em R$ ou horas. Permissão verbal não é dor: faço pergunta de contexto que obrigue o comprador a falar de si. [...] Quando o cliente exige prova de credibilidade, respondo com fato verificável em uma frase, declaro o *gap* em uma frase e condiciono a entrega completa a uma troca mínima de contexto dele."